Redes tensoriales para ia neuro-simbolica

Un manual paso a paso para estudiantes de pregrado

con analogias de electricidad y magnetismo

Basado en el paper:

"A tensor network formalism for neuro-symbolic ai"
Goessmann, Schutte, Frohlich, Eigel
`arXiv:2601.15442` — enero 2026

A quien va dirigido este manual?
A estudiantes universitarios que conocen algebra lineal basica, calculo y algo de electromagnetismo. No se requiere experiencia previa en inteligencia artificial ni en fisica cuantica.

Manual de estudio — 2026

Índice

1. De que trata todo esto? — La idea en dos minutos **3**

2. El mapa del paper — como se relaciona todo **3**
2.1. Recreacion del diagrama del paper . . . 4
2.2. Como leer el diagrama . . . 4
2.3. Los dos conceptos nuevos del centro . . . 4
2.4. La lectura de afuera hacia adentro . . . 5
2.5. La hoja de ruta del manual . . . 5

3. Modulo 1: que es un tensor? — desde cero **6**
3.1. Escalares, vectores, matrices... y tensores . . . 6
3.2. Notacion usada en este manual . . . 6

4. Modulo 2: la operacion de contraccion — el corazon de todo **7**
4.1. Que es una contraccion? . . . 7
4.2. Contraccion de tensores de orden mayor . . . 7

5. Modulo 3: redes tensoriales — conectar tensores entre si **8**
5.1. La idea de una red tensorial . . . 8
5.2. Por que usar redes tensoriales? . . . 9

6. Modulo 4: descomposiciones tensoriales **9**
6.1. Descomposicion CP — suma de productos . . . 9
6.2. Figura 2 del paper: dos formas de ver la descomposicion CP . . . 10
6.2.1. Diagrama a) — vista de hipergrafo . . . 11
6.2.2. Diagrama b) — vista de red tensorial . . . 11
6.2.3. La diferencia clave entre a) y b) . . . 11
6.3. Descomposicion tensor train — cadenas de matrices . . . 12
6.4. Ejemplo 2 del paper: el formato CP en lenguaje formal . . . 13
6.4.1. Los nodos: variables visibles y variable oculta . . . 13
6.4.2. Las aristas: los tensores de factor . . . 13
6.4.3. La formula completa . . . 14
6.5. Ejemplo 3 del paper: el formato TT en lenguaje formal . . . 14
6.5.1. La diferencia clave con el formato CP . . . 15
6.5.2. Las tres clases de aristas del TT . . . 15
6.5.3. El diagrama del formato TT . . . 16
6.5.4. La formula completa del TT . . . 16
6.5.5. CP vs TT: la diferencia en una imagen . . . 17
6.6. Figura 3 del paper: como leer el diagrama TT . . . 17
6.6.1. Diagrama a) — el hipergrafo del TT . . . 17
6.6.2. Diagrama b) — la red tensorial del TT . . . 18
6.6.3. La historia que cuenta el diagrama b): una linea de ensamblaje . . . 18
6.7. Figura 4 del paper: contraccion con variables abiertas . . . 20
6.7.1. Que dice la figura . . . 20
6.7.2. La notacion $\langle\cdot\rangle_{[X_1,X_3]}$ . . . 20
6.7.3. La regla del punto — como leer el diagrama . . . 20
6.7.4. Recreacion del diagrama de la Figura 4 . . . 21

6.7.5. Como leer cada cuadro del diagrama 21
6.7.6. La formula matematica completa 21
6.8. Figura 5 del paper: variables independientes 23
6.8.1. Diagrama a) — el hipergrafo elemental 23
6.8.2. Diagrama b) — la red tensorial de independencia 24
6.8.3. La formula matematica 24

7. Modulo 5: codificacion en base — datos como tensores 26
7.1. Como convertir datos en vectores 26

8. Modulo 6: logica proposicional como tensores 27
8.1. Variables verdadero/falso como vectores 27
8.2. Las conectivas logicas como tensores 27

9. Modulo 7: probabilidad como tensores 29

10. Modulo 8: paso de mensajes — inferencia eficiente 30

11. Modulo 9: redes neuronales como redes tensoriales 31
11.1. Una capa neuronal es una contraccion tensorial 31

12. Modulo 10: el modelo final — hybrid logic network 32
12.1. La distribucion del HLN 32

1. De que trata todo esto? — La idea en dos minutos

Imagina que tienes dos tipos de herramientas para hacer inteligencia artificial:

- **Las redes neuronales:** aprenden de datos, reconocen patrones, pero no razonan con logica. Son como un estudiante que memoriza sin entender.
- **La logica simbolica:** razona con reglas ("si llueve, entonces el suelo se moja"), pero no aprende de datos. Es como un libro de texto sin ejemplos.

El paper propone una idea muy elegante: **ambas cosas son, en el fondo, operaciones con tensores**. Si usamos el mismo lenguaje matematico (las redes tensoriales), podemos combinarlas en un solo modelo que aprende *y* razona.

Analogia con electricidad y magnetismo: El circuito electrico unificado

En electricidad tienes resistencias, capacitores e inductores. Por separado parecen cosas distintas, pero todos se describen con la misma ecuacion: la impedancia compleja Z. La corriente y el voltaje obedecen la misma ley $V = ZI$ independientemente del componente. Las redes tensoriales hacen lo mismo con la ia: unifican conceptos distintos bajo un solo formalismo matematico.

Idea clave

La pregunta central del paper es: existe un lenguaje matematico que describa a la vez las redes neuronales, la logica y la probabilidad? La respuesta es si: ese lenguaje son las **redes tensoriales**.

2. El mapa del paper — como se relaciona todo

Antes de entrar en los detalles matematicos, conviene tener una vision de conjunto. La siguiente figura aparece en el paper y resume su propuesta completa. Vamos a estudiarla despacio.

2.1. Recreacion del diagrama del paper

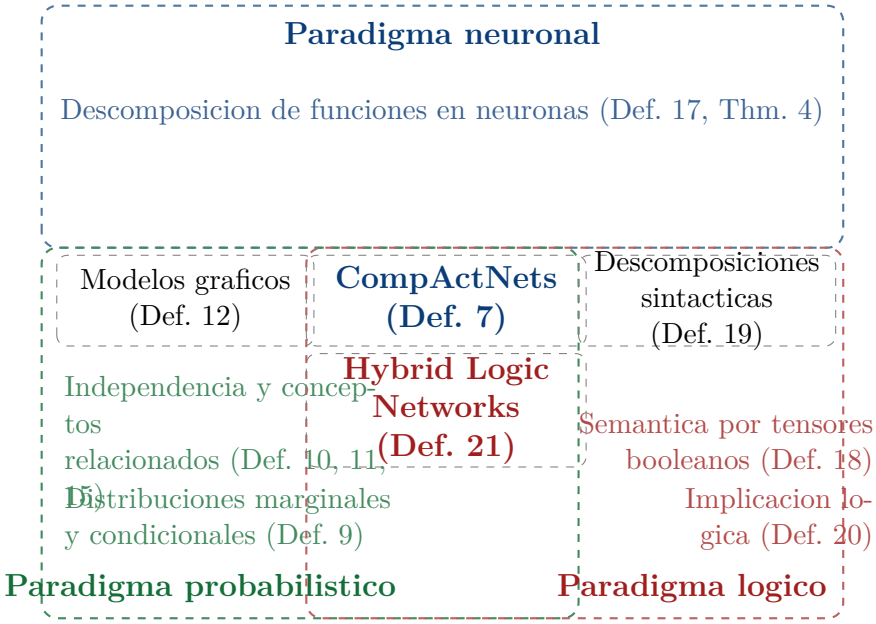

2.2. Como leer el diagrama

El diagrama tiene **tres grandes regiones** que representan los tres paradigmas de la IA. Lo que ya existia antes del paper vive en las esquinas. Lo nuevo esta en el centro, donde los tres paradigmas se solapan.

Region	Que contiene
Arriba	El paradigma **neuronal**: redes neuronales profundas, aprendizaje automatico, funciones aproximadas por capas de neuronas.
Abajo izquierda	El paradigma **probabilistico**: distribuciones de probabilidad, modelos graficos (redes bayesianas, campos de Markov), independencia estadistica, marginales.
Abajo derecha	El paradigma **logico**: formulas booleanas, tablas de verdad, implicacion logica, razonamiento exacto y determinista.
Centro	Lo nuevo del paper: **CompActNets** y **HLN**. Son posibles solo porque el formalismo tensorial unifica los tres paradigmas.

2.3. Los dos conceptos nuevos del centro

CompActNets (Def. 7) — la arquitectura unificada

Una CompActNet es una red tensorial que puede representar a la vez funciones neuronales, distribuciones de probabilidad y formulas logicas. Es el "lenguaje comun" que unifica los tres paradigmas. Internamente tiene dos sub-redes: una que *computa* (parte logica, determinista) y otra que *activa* (parte probabilistica y neuronal).

Hybrid Logic Networks (Def. 21) — el modelo final

Un HLN es una distribucion de probabilidad donde las "energias" son formulas logicas con pesos aprendibles. Combina los tres paradigmas en un solo modelo entrenable: aprende de datos (neuronal), razona con reglas (logico) y maneja incertidumbre (probabilistico). Lo estudiaremos en detalle en el Modulo 10.

2.4. La lectura de afuera hacia adentro

Cuantos paradigmas combinados	Que obtienes
Solo uno	Herramientas clasicas: redes neuronales, o estadistica, o logica. Cada una con sus limitaciones conocidas.
Dos juntos	Modelos graficos probabilisticos (prob + neural), descomposiciones sintacticas (logica + neural).
Los tres juntos	**CompActNets** y **HLN**: el aporte original del paper. Un modelo que aprende, razona y maneja incertidumbre al mismo tiempo.

Analogia con electricidad y magnetismo: El circuito RLC

En electromagnetismo tienes tres elementos pasivos: la resistencia R (disipa energia), el capacitor C (almacena energia en campo electrico) y el inductor L (almacena energia en campo magnetico). Por separado, cada uno modela fenomenos simples. Juntos en un circuito RLC aparecen fenomenos nuevos: resonancia, respuesta en frecuencia, filtros selectivos. Igual ocurre en el paper: al unir los tres paradigmas en un solo formalismo tensorial emergen capacidades que ninguno tenia por separado — modelos que razonan con incertidumbre y aprenden al mismo tiempo.

2.5. La hoja de ruta del manual

Ahora que tienes el mapa completo, el manual sigue este recorrido:

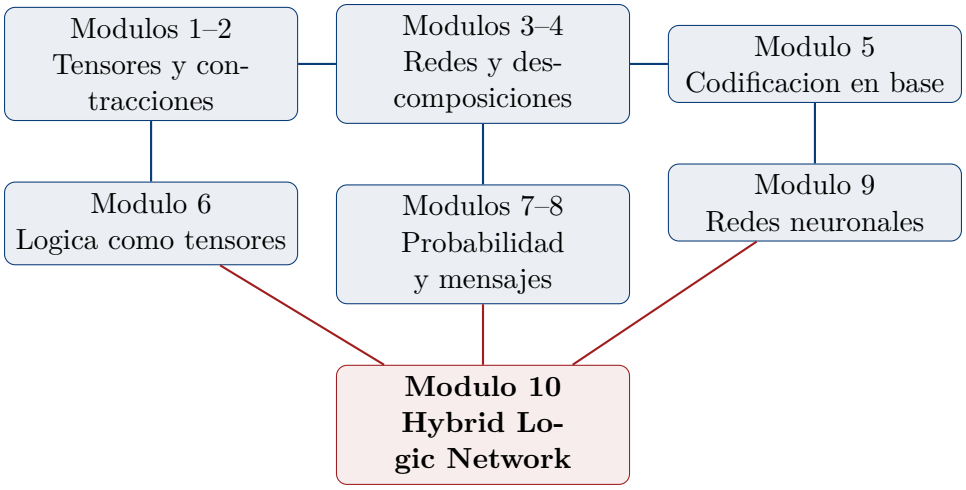

Todo converge en el Modulo 10, que corresponde exactamente al centro del diagrama del paper.

3. Modulo 1: que es un tensor? — desde cero

3.1. Escalares, vectores, matrices... y tensores

Ya conoces estas ideas:

- Un **escalar** es un solo numero: $a = 5$.
- Un **vector** es una lista de numeros: $\mathbf{v} = (3,\ 1,\ 4)$.
- Una **matriz** es una tabla de numeros: $\mathbf{M} = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix}$.

Un **tensor** generaliza esta idea a cualquier numero de dimensiones. Una matriz es un tensor de orden 2 (tiene dos indices: fila y columna). Un tensor de orden 3 es como un cubo de numeros: tiene tres indices.

Ejemplo 1.1 — Un tensor de orden 3

Imagina que guardas la temperatura de una ciudad hora por hora durante un mes. Necesitas tres indices: dia i, hora j, y sensor de medicion k. Eso es un tensor $\mathcal{T}$ de orden 3:

$$\mathcal{T}_{i,j,k} = \text{temperatura en el dia } i,\ \text{hora } j,\ \text{sensor } k$$

Si tienes 30 dias, 24 horas y 5 sensores, el tensor tiene $30 \times 24 \times 5 = 3600$ entradas.

Analogia con electricidad y magnetismo: El campo electrico

El campo electrico $\mathbf{E}(x, y, z, t)$ depende de la posicion y del tiempo, y tiene tres componentes (E_x, E_y, E_z). Si lo discretizas en una grilla de N puntos en cada coordenada y T instantes, tienes un tensor de orden 4 con $N^3 \times T \times 3$ entradas. Las simulaciones de electromagnetismo son, literalmente, operaciones con tensores.

3.2. Notacion usada en este manual

- Letras minusculas cursivas para escalares: a, b, x.
- Letras minusculas en negrita para vectores: $\mathbf{v}$, $\mathbf{u}$.
- Letras mayusculas en negrita para matrices: $\mathbf{M}$, $\mathbf{W}$.
- Letras caligraticas para tensores de orden ≥ 3: $\mathcal{A}$, $\mathcal{T}$, $\mathcal{F}$.

4. Modulo 2: la operacion de contraccion — el corazon de todo

4.1. Que es una contraccion?

La **contraccion** es la operacion mas importante en el formalismo del paper. Es una generalizacion del producto punto entre vectores y de la multiplicacion de matrices.

Ejemplo 2.1 — Producto punto entre vectores

Dados dos vectores $\mathbf{u} = (2,\, 3,\, 1)$ y $\mathbf{v} = (4,\, 0,\, 5)$, el producto punto es:

$$\mathbf{u} \cdot \mathbf{v} = \sum_{i=1}^{3} u_i\, v_i = (2)(4) + (3)(0) + (1)(5) = 8 + 0 + 5 = 13$$

Sumamos sobre el indice compartido i. Eso es una **contraccion sobre un indice**.

Ejemplo 2.2 — Multiplicacion de matrices

La multiplicacion $\mathbf{C} = \mathbf{AB}$ con $\mathbf{A} \in \mathbb{R}^{2\times 3}$ y $\mathbf{B} \in \mathbb{R}^{3\times 2}$ es:

$$C_{ik} = \sum_{j=1}^{3} A_{ij}\, B_{jk}$$

Sumamos sobre el indice j que comparten $\mathbf{A}$ y $\mathbf{B}$. Con los valores:

$$\mathbf{A} = \begin{pmatrix} 1 & 2 & 0 \\ 3 & 1 & 1 \end{pmatrix}, \qquad \mathbf{B} = \begin{pmatrix} 1 & 0 \\ 2 & 1 \\ 0 & 3 \end{pmatrix}$$

calculamos cada entrada:

$$\begin{aligned} C_{11} &= (1)(1) + (2)(2) + (0)(0) = 1 + 4 + 0 = 5 \\ C_{12} &= (1)(0) + (2)(1) + (0)(3) = 0 + 2 + 0 = 2 \\ C_{21} &= (3)(1) + (1)(2) + (1)(0) = 3 + 2 + 0 = 5 \\ C_{22} &= (3)(0) + (1)(1) + (1)(3) = 0 + 1 + 3 = 4 \end{aligned}$$

$$\mathbf{C} = \begin{pmatrix} 5 & 2 \\ 5 & 4 \end{pmatrix}$$

4.2. Contraccion de tensores de orden mayor

La idea es exactamente la misma, pero con mas indices.

Ejemplo 2.3 — Contraccion de un tensor con un vector

Sea $\mathcal{A} \in \mathbb{R}^{2\times2\times2}$ un tensor de orden 3 con entradas $\mathcal{A}_{ijk}$ donde $i, j, k \in \{1, 2\}$, y sea $\mathbf{v} = (1,\ 0)^\top$. La contraccion de $\mathcal{A}$ con $\mathbf{v}$ en el tercer indice produce una **matriz**:

$$M_{ij} = \sum_{k=1}^{2} \mathcal{A}_{ijk}\, v_k = \mathcal{A}_{ij1} \cdot 1 + \mathcal{A}_{ij2} \cdot 0 = \mathcal{A}_{ij1}$$

Seleccionamos la "capa" $k = 1$ del cubo. Si $\mathbf{v} = (0,\ 1)^\top$, obtendriamos la capa $k = 2$.

Analogia con electricidad y magnetismo: La ley de Ohm como contraccion

En un circuito con n nodos, la ley de Ohm en forma matricial es:

$$V_i = \sum_j R_{ij}\, I_j$$

donde R_{ij} es la resistencia entre nodos y I_j la corriente. Esto es exactamente una contraccion del tensor $\mathbf{R}$ (de orden 2, una matriz) con el vector $\mathbf{I}$ sobre el indice j. Toda la electrostática lineal se puede escribir como contracciones tensoriales.

Ejercicio 2.1

Dados $\mathbf{a} = (1,\ 2,\ 3)$ y $\mathbf{b} = (2,\ 0,\ 1)$, calcula el producto punto $\mathbf{a} \cdot \mathbf{b}$.
Luego, dado $\mathbf{M} = \begin{pmatrix} 2 & 1 \\ 0 & 3 \end{pmatrix}$ y $\mathbf{v} = \begin{pmatrix} 1 \\ 2 \end{pmatrix}$, calcula $\mathbf{Mv}$ paso a paso.

5. Modulo 3: redes tensoriales — conectar tensores entre si

5.1. La idea de una red tensorial

Una **red tensorial** es un conjunto de tensores conectados entre si mediante contracciones. Se dibuja como un grafo donde:

- Cada **nodo** es un tensor.
- Cada **arista interna** (que conecta dos nodos) representa un indice que se contrae (se suma).
- Cada **arista colgante** (que no conecta nada) es un indice libre (de salida).

Ejemplo 3.1 — Una red tensorial pequena

Considera la expresion $\mathbf{y} = \mathbf{ABx}$ donde $\mathbf{A}, \mathbf{B}$ son matrices y $\mathbf{x}$ es un vector. La red tensorial es una cadena de tres nodos:

indice contraido

Se evalua de derecha a izquierda: paso 1: $\mathbf{u} = \mathbf{Bx}$; paso 2: $\mathbf{y} = \mathbf{Au}$.

Analogia con electricidad y magnetismo: Resistencias en serie

Una cadena de resistencias R_1, R_2, R_3 en serie entre dos terminales tiene resistencia total $R_{total} = R_1 + R_2 + R_3$. La corriente "fluye" de nodo en nodo, igual que los indices se "pasan" de tensor en tensor en una red tensorial.

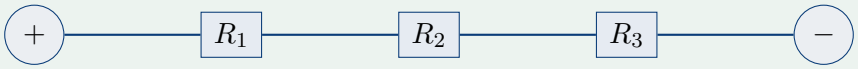

5.2. Por que usar redes tensoriales?

Ejemplo 3.2 — La explosion exponencial

Con 10 variables binarias, el numero de estados posibles es $2^{10} = 1024$. Con 100 variables: $2^{100} \approx 10^{30}$ estados. Eso es mas que el numero de atomos en el universo observable. Un tensor que guarde todas las posibilidades es imposible de almacenar. Pero si el tensor tiene **estructura** (por ejemplo, cada variable solo interactua con sus vecinas), podemos representarlo como una cadena de matrices pequenas. Esa es la magia de las redes tensoriales.

Atencion

El principal desafio de la ia no es la fuerza bruta sino la **estructura**. Las redes tensoriales explotan esa estructura para hacer calculos que de otra manera serian imposibles.

Ejercicio 3.1

Tienes 5 variables binarias ($x_1, x_2, x_3, x_4, x_5 \in \{0, 1\}$). Cuantas entradas tiene el tensor que enumera todos los estados posibles? Y para 20 variables?

6. Modulo 4: descomposiciones tensoriales

6.1. Descomposicion CP — suma de productos

Idea clave

La descomposicion CP dice: puedo escribir un tensor complicado como una suma de pocos terminos simples. Cada termino es el producto externo de vectores.

Ejemplo 4.1 — Descomposicion CP de una matriz (rango 1)

Sea la matriz:

$$\mathbf{M} = \begin{pmatrix} 2 & 4 \\ 1 & 2 \end{pmatrix}$$

La fila 2 es exactamente la mitad de la fila 1, entonces el rango es 1 y podemos escribir:

$$\mathbf{M} = \begin{pmatrix} 2 \\ 1 \end{pmatrix} \begin{pmatrix} 1 & 2 \end{pmatrix} = \mathbf{u}\,\mathbf{v}^\top$$

En lugar de guardar $2 \times 2 = 4$ numeros de forma independiente, basta guardar $2 + 2 = 4$ (aqui el ahorro es igual, pero para una matriz 1000×1000 de rango 5 pasamos de 10^6 a solo $5 \times 2000 = 10^4$ parametros).

Ejemplo 4.2 — Descomposicion CP general

Para un tensor de orden 3 $\mathcal{A} \in \mathbb{R}^{d \times d \times d}$, la descomposicion CP con rango r es:

$$\mathcal{A}_{ijk} = \sum_{\alpha=1}^{r} u_\alpha^{(i)}\, v_\alpha^{(j)}\, w_\alpha^{(k)}$$

Numero de parametros original: d^3. Con CP de rango r: $3rd$. Para $d = 100$ y $r = 5$: pasamos de 10^6 a 1500 parametros. Un factor de 667 veces menos.

Analogia con electricidad y magnetismo: Modos de vibracion de una antena

Cuando analizas los modos normales de una cavidad resonante, la solucion general es suma de modos simples. Cada modo es una funcion separable (producto de funciones en cada coordenada). La descomposicion CP es exactamente eso: descomponer un tensor en sus "modos normales tensoriales". Cada termino $\mathbf{u}_\alpha \otimes \mathbf{v}_\alpha \otimes \mathbf{w}_\alpha$ es un modo de rango 1.

6.2. Figura 2 del paper: dos formas de ver la descomposicion CP

El paper presenta esta misma idea en dos diagramas que representan **exactamente la misma cosa** desde angulos distintos. Vamos a entenderlos uno por uno.

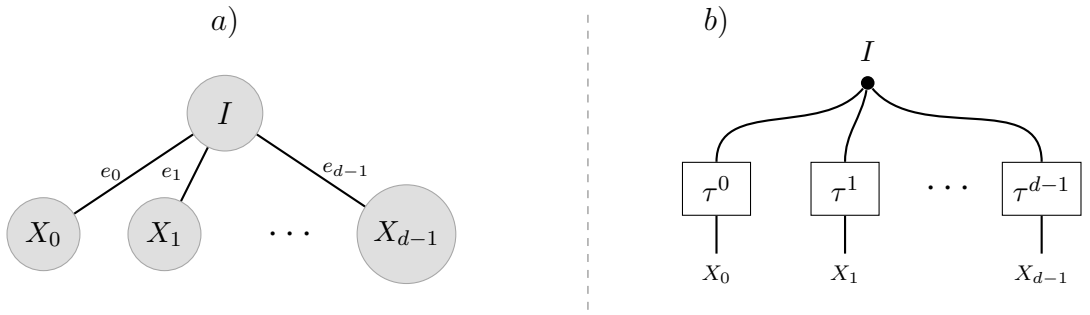

Figura 2 del paper: hipergrafo de la descomposicion CP (izquierda) y su red tensorial correspondiente (derecha).

6.2.1. Diagrama a) — vista de hipergrafo

El nodo central I es el **indice de suma** de la CP (el indice α que recorre de 1 a r, el rango del tensor). Cada nodo hijo X_k es una **variable del problema** (la k-esima dimension del tensor). La arista e_k conecta el indice de suma con la variable k.

Lo que el grafo comunica visualmente es esto: *hay un unico indice central I que relaciona todas las variables entre si.* Esa es exactamente la estructura de la CP:

$$\mathcal{A}_{i_0,i_1,\ldots,i_{d-1}} = \sum_{\alpha=1}^{r} \tau^0_{\alpha,\,i_0}\ \tau^1_{\alpha,\,i_1}\ \cdots\ \tau^{d-1}_{\alpha,\,i_{d-1}}$$

El indice α (el nodo I) actua como "intermediario" que conecta todos los factores a la vez.

6.2.2. Diagrama b) — vista de red tensorial

Ahora los cuadros $\tau^0, \tau^1, \ldots, \tau^{d-1}$ son los **tensores de factor**: matrices de tamano $r \times d$ (rango $\times$ dimension). El punto negro I en la cima es el **indice compartido** que los une.

Cada cuadro τ^k tiene dos aristas:

- La arista **superior** (curva hacia I): es el indice interno α, que se contrae (se suma). Por eso se llama indice "virtual" o de enlace.
- La arista **inferior** (hacia X_k): es el indice externo i_k, que queda libre y corresponde a la k-esima dimension del tensor resultante.

Elemento del dibujo	**Significado matematico**
Nodo I / punto I	Indice de suma $\alpha \in \{1, \ldots, r\}$
Nodo X_k / etiqueta X_k	Variable (indice libre) i_k
Cuadro τ^k	Vector de factor $\mathbf{u}^{(k)} \in \mathbb{R}^{r\times d}$
Curva hacia I	Indice contraido: $\sum_\alpha$
Arista inferior de τ^k	Indice libre: la k-esima dimension del tensor

6.2.3. La diferencia clave entre a) y b)

En el diagrama **a)** los *nodos son las variables* y las aristas son las relaciones entre ellas.

En el diagrama **b)** los *nodos son los tensores* y las aristas son los indices (los "cables" que transportan informacion).

Son dos lenguajes para el mismo objeto matematico, igual que en un circuito puedes aplicar la ley de nodos de Kirchhoff (corrientes en cada nodo) o la ley de mallas (voltajes en cada lazo): ambas describen el mismo circuito pero desde perspectivas diferentes.

Ejemplo 4.3 — Figura 2 con $d = 3$ y numeros concretos

Sea un tensor $\mathcal{A} \in \mathbb{R}^{4\times4\times4}$ (orden 3, dimension 4) con descomposicion CP de rango $r = 2$. Los tres factores son:

$$\tau^0 = \begin{pmatrix} 1 & 0 & 2 & 1 \\ 3 & 1 & 0 & 2 \end{pmatrix} \in \mathbb{R}^{2\times4}, \quad \tau^1 = \begin{pmatrix} 0 & 1 & 1 & 0 \\ 2 & 0 & 1 & 3 \end{pmatrix} \in \mathbb{R}^{2\times4}, \quad \tau^2 = \begin{pmatrix} 1 & 1 & 0 & 2 \\ 0 & 2 & 1 & 1 \end{pmatrix} \in \mathbb{R}^{2\times4}$$

La entrada $(i_0 = 1,\ i_1 = 2,\ i_2 = 0)$ del tensor es:

$$\begin{aligned} \mathcal{A}_{1,2,0} &= \sum_{\alpha=1}^{2} \tau^0_{\alpha,1} \cdot \tau^1_{\alpha,2} \cdot \tau^2_{\alpha,0} \\ &= \tau^0_{1,1} \cdot \tau^1_{1,2} \cdot \tau^2_{1,0} + \tau^0_{2,1} \cdot \tau^1_{2,2} \cdot \tau^2_{2,0} \\ &= (0) \cdot (1) \cdot (1) + (1) \cdot (1) \cdot (0) \\ &= 0 + 0 = 0 \end{aligned}$$

En el diagrama b), el punto I suma los dos terminos ($\alpha = 1$ y $\alpha = 2$), y cada cuadro τ^k selecciona la fila α y la columna i_k.

Ejercicio 4.3

Usando los mismos factores del ejemplo anterior, calcula $\mathcal{A}_{0,1,2}$ siguiendo el mismo procedimiento paso a paso. Luego dibuja el diagrama b) de la Figura 2 para este caso ($d = 3$) etiquetando los indices α e i_k en cada arista.

6.3. Descomposicion tensor train — cadenas de matrices

Idea clave

La descomposicion tensor train dice: puedo escribir un tensor de orden n como un producto de n matrices pequenas conectadas en cadena.

Ejemplo 4.3 — Tensor train con numeros

Un tensor $\mathcal{A} \in \mathbb{R}^{2\times2\times2}$ en formato tensor train con rango $r = 2$:

$$\mathcal{A}_{i_1,i_2,i_3} = \sum_{\alpha_1=1}^{2} \sum_{\alpha_2=1}^{2} G^{(1)}_{i_1,\alpha_1}\, G^{(2)}_{\alpha_1,i_2,\alpha_2}\, G^{(3)}_{\alpha_2,i_3}$$

El diagrama de la cadena:

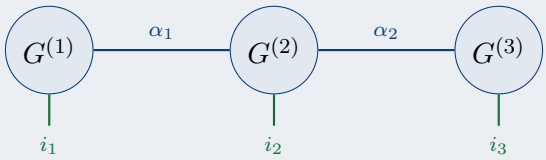

Las aristas azules son indices internos (se contraen), las verdes son indices externos (los datos).

Analogia con electricidad y magnetismo: Red de distribucion electrica en cascada

Imagina n subestaciones electricas en serie: cada una recibe la senal de la anterior, la transforma (con su matriz de transferencia $G^{(k)}$) y la pasa a la siguiente. El tensor train es matematicamente identico: una cadena de transformaciones donde la informacion fluye de un extremo al otro.

6.4. Ejemplo 2 del paper: el formato CP en lenguaje formal

El paper describe el formato CP usando la siguiente definicion:

Cita del paper (Ejemplo 2, traducida)

El formato CP corresponde a un hipergrafo definido por:

- Nodos $X_{[d]}$ y una sola variable oculta I, decorados por dimensiones $m_{[d]}$ y el rango CP n, respectivamente.
- Aristas $e_k = \{X_k,\, I\}$ para cada $k \in [d]$, cada una decorada por una matriz $\tau^{e_k}[X_k,\, I] \in \mathbb{R}^{m_k \times n}$.

Vamos a traducir cada pieza de esta definicion al lenguaje simple que ya conocemos.

6.4.1. Los nodos: variables visibles y variable oculta

Termino del paper	Simbolo	Que significa
Nodos $X_{[d]}$	$X_0, X_1, \ldots, X_{d-1}$	Las d dimensiones del tensor. Son los nodos hijos del diagrama a).
Variable oculta I	I	El indice de suma α de la CP. No aparece en los datos, solo existe internamente para conectar todos los factores.
Dimension m_k	m_k	Cuantos valores puede tomar X_k (el tamano del modo k del tensor).
Rango CP n	n	Cuantos terminos tiene la suma $\sum_\alpha$. Es la dimension de I.

6.4.2. Las aristas: los tensores de factor

Cada arista $e_k = \{X_k, I\}$ conecta la variable X_k con el nodo central I, y lleva asociada una **matriz**:

$$\tau^{e_k}[X_k,\, I] \;\in\; \mathbb{R}^{m_k \times n}$$

La notacion $[X_k, I]$ indica los dos indices de esta matriz:

- El indice $X_k \in \{0, \ldots, m_k - 1\}$: el indice **libre** (la k-esima dimension del tensor resultante).
- El indice $I \in \{1, \ldots, n\}$: el indice **contraido** (el α de la suma CP).

Idea clave

La matriz τ^{e_k} es exactamente el factor k de la descomposicion CP. Su fila i_k y columna α dan el valor $u_\alpha^{(k)}(i_k)$ de la formula clasica. El paper simplemente lo escribe de forma mas general usando la notacion de hipergrafo.

6.4.3. La formula completa

Juntando todo, el tensor queda:

$$\boxed{\mathcal{A}_{i_0,\, i_1,\, \ldots,\, i_{d-1}} \;=\; \sum_{\alpha=1}^{n} \prod_{k=0}^{d-1} \tau^{e_k}[i_k,\, \alpha]}$$

Para cada combinacion de indices $(i_0, \ldots, i_{d-1})$, se suma sobre α el producto de las entradas correspondientes de cada matriz de factor. El nodo I "coordina" esa suma.

Ejemplo 4.4 — Ejemplo 2 del paper con numeros ($d = 3$, $n = 2$)

Tensor de orden 3 ($d = 3$), dimensiones $m_0 = m_1 = m_2 = 3$, rango CP $n = 2$. Los tres factores (matrices de 3×2):

$$\tau^{e_0} = \begin{pmatrix} 1 & 2 \\ 0 & 1 \\ 3 & 0 \end{pmatrix}, \quad \tau^{e_1} = \begin{pmatrix} 0 & 1 \\ 2 & 0 \\ 1 & 1 \end{pmatrix}, \quad \tau^{e_2} = \begin{pmatrix} 1 & 0 \\ 0 & 2 \\ 1 & 1 \end{pmatrix}$$

Calculamos la entrada ($i_0 = 0$, $i_1 = 1$, $i_2 = 2$):

$$\begin{aligned}
\mathcal{A}_{0,1,2} &= \sum_{\alpha=1}^{2} \tau^{e_0}[0, \alpha] \cdot \tau^{e_1}[1, \alpha] \cdot \tau^{e_2}[2, \alpha] \\
&= \underbrace{\tau^{e_0}[0, 1]}_{\alpha=1} \cdot \underbrace{\tau^{e_1}[1, 1]}_{\alpha=1} \cdot \underbrace{\tau^{e_2}[2, 1]}_{\alpha=1} + \underbrace{\tau^{e_0}[0, 2]}_{\alpha=2} \cdot \underbrace{\tau^{e_1}[1, 2]}_{\alpha=2} \cdot \underbrace{\tau^{e_2}[2, 2]}_{\alpha=2} \\
&= (1) \cdot (2) \cdot (1) + (2) \cdot (0) \cdot (2) \\
&= 2 + 0 \;=\; 2
\end{aligned}$$

Eso es todo: dos productos, una suma. El nodo I en el diagrama representa exactamente esa suma sobre $\alpha \in \{1, 2\}$.

6.5. Ejemplo 3 del paper: el formato TT en lenguaje formal

El Ejemplo 3 del paper hace lo mismo para el formato Tensor Train (TT).

Cita del paper (Ejemplo 3, traducida)

El formato TT corresponde a un hipergrafo definido por:

- Nodos $X_{[d]}$ y variables ocultas $I_{[d-1]}$, decorados por dimensiones $m_{[d]}$ y rangos TT $n_{[d-1]}$, respectivamente.
- Aristas de extremo: $e_0 = \{X_0, I_0\}$ y $e_{d-1} = \{X_{d-1}, I_{d-2}\}$, cada una con su tensor de factor.
- Aristas internas: $e_k = \{X_k, I_{k-1}, I_k\}$ para $k \in \{1, \ldots, d-2\}$, cada una decorada por un tensor $\tau^{e_k}[X_k, I_{k-1}, I_k] \in \mathbb{R}^{m_k \times n_{k-1} \times n_k}$.

6.5.1. La diferencia clave con el formato CP

En CP habia **un solo** nodo oculto I que conectaba todas las variables a la vez (estructura en estrella). En TT hay **una cadena** de nodos ocultos $I_0, I_1, \ldots, I_{d-2}$ que conectan las variables una a una (estructura lineal).

	Formato CP	**Formato TT**
Estructura	Estrella: un I central	Cadena: $I_0, I_1, \ldots, I_{d-2}$
Variables ocultas	1 sola (I)	$d-1$ (I_0 hasta I_{d-2})
Tipo de aristas	Todas de grado 2: $\{X_k, I\}$	Extremos de grado 2, internas de grado 3
Tensor en arista	Matriz $\mathbb{R}^{m_k \times n}$	Tensor de orden 3 $\mathbb{R}^{m_k \times n_{k-1} \times n_k}$

6.5.2. Las tres clases de aristas del TT

El TT tiene tres tipos de aristas, segun donde esta el nodo en la cadena:

1. Arista del extremo izquierdo ($k = 0$):

$$e_0 = \{X_0,\, I_0\}, \qquad \tau^{e_0}[X_0,\, I_0] \;\in\; \mathbb{R}^{m_0 \times n_0}$$

Es una matriz: un indice libre (X_0) y un indice de enlace (I_0).

2. Aristas internas ($1 \leq k \leq d-2$):

$$e_k = \{X_k,\, I_{k-1},\, I_k\}, \qquad \tau^{e_k}[X_k,\, I_{k-1},\, I_k] \;\in\; \mathbb{R}^{m_k \times n_{k-1} \times n_k}$$

Es un tensor de orden 3: un indice libre (X_k) y **dos** indices de enlace (I_{k-1} recibido de la izquierda, I_k enviado a la derecha).

3. Arista del extremo derecho ($k = d-1$):

$$e_{d-1} = \{X_{d-1},\, I_{d-2}\}, \qquad \tau^{e_{d-1}}[X_{d-1},\, I_{d-2}] \;\in\; \mathbb{R}^{m_{d-1} \times n_{d-2}}$$

De nuevo una matriz: un indice libre (X_{d-1}) y un indice de enlace (I_{d-2}, recibido de la izquierda).

6.5.3. El diagrama del formato TT

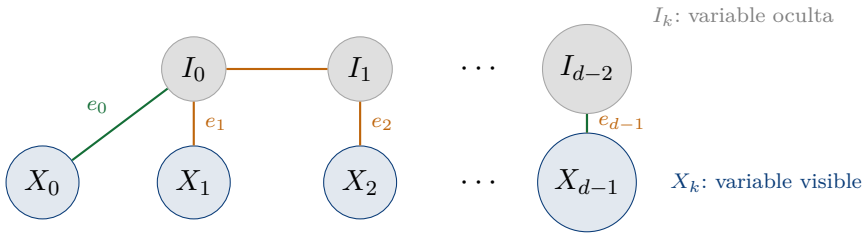

6.5.4. La formula completa del TT

$$\boxed{\mathcal{A}_{i_0,i_1,\ldots,i_{d-1}} = \sum_{\alpha_0=1}^{n_0} \sum_{\alpha_1=1}^{n_1} \cdots \sum_{\alpha_{d-2}=1}^{n_{d-2}} \tau^{e_0}[i_0,\alpha_0]\, \tau^{e_1}[i_1,\alpha_0,\alpha_1]\, \cdots\, \tau^{e_{d-1}}[i_{d-1},\alpha_{d-2}]}$$

Cada α_k es el "mensaje" que pasa entre la variable X_k y la variable X_{k+1}, a traves del nodo oculto I_k.

Ejemplo 4.5 — Ejemplo 3 del paper con numeros ($d = 3$, $n_0 = n_1 = 2$)

Tensor de orden 3 ($d = 3$), dimensiones $m_0 = m_1 = m_2 = 2$, rangos TT $n_0 = n_1 = 2$. Los tres factores:

$$\tau^{e_0} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \in \mathbb{R}^{2\times 2}, \quad \tau^{e_1}[:,:,:] \text{ (tensor de orden 3)}, \quad \tau^{e_2} = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \in \mathbb{R}^{2\times 2}$$

Para $\tau^{e_1} \in \mathbb{R}^{2\times 2\times 2}$ usamos:

$$\tau^{e_1}[i_1 = 0,\, :,\, :] = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}, \qquad \tau^{e_1}[i_1 = 1,\, :,\, :] = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$$

Calculamos $\mathcal{A}_{0,1,0}$:

$$\mathcal{A}_{0,1,0} = \sum_{\alpha_0=1}^{2} \sum_{\alpha_1=1}^{2} \tau^{e_0}[0,\alpha_0] \cdot \tau^{e_1}[1,\alpha_0,\alpha_1] \cdot \tau^{e_2}[0,\alpha_1]$$

Expandimos los cuatro terminos ($\alpha_0 \in \{1,2\}$, $\alpha_1 \in \{1,2\}$):

$$\begin{aligned}
(\alpha_0{=}1,\ \alpha_1{=}1):&\quad \tau^{e_0}[0,1] \cdot \tau^{e_1}[1,1,1] \cdot \tau^{e_2}[0,1] = (1)(0)(1) = 0 \\
(\alpha_0{=}1,\ \alpha_1{=}2):&\quad \tau^{e_0}[0,1] \cdot \tau^{e_1}[1,1,2] \cdot \tau^{e_2}[0,2] = (1)(1)(1) = 1 \\
(\alpha_0{=}2,\ \alpha_1{=}1):&\quad \tau^{e_0}[0,2] \cdot \tau^{e_1}[1,2,1] \cdot \tau^{e_2}[0,1] = (0)(1)(1) = 0 \\
(\alpha_0{=}2,\ \alpha_1{=}2):&\quad \tau^{e_0}[0,2] \cdot \tau^{e_1}[1,2,2] \cdot \tau^{e_2}[0,2] = (0)(0)(1) = 0
\end{aligned}$$

$$\mathcal{A}_{0,1,0} = 0 + 1 + 0 + 0 = 1$$

6.5.5. CP vs TT: la diferencia en una imagen

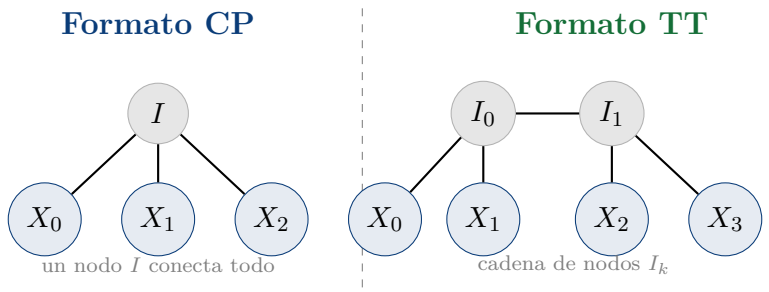

Analogia con electricidad y magnetismo: Dos tipos de circuitos

El formato CP es como un **bus electrico**: un conductor central al que se conectan todos los dispositivos en paralelo. Cada dispositivo (τ^{e_k}) se comunica directamente con el bus (I).
El formato TT es como una **red en cadena** (daisy chain): los dispositivos se conectan en serie, uno detras del otro. La informacion (α_k) viaja de nodo en nodo hasta llegar al final. En electronica, la comunicacion I^{2}C funciona exactamente asi.

6.6. Figura 3 del paper: como leer el diagrama TT

La Figura 3 del paper hace para el TT lo que la Figura 2 hizo para el CP: muestra el mismo objeto desde dos perspectivas. Vamos a leerla con mucho cuidado porque contiene mas informacion que la Figura 2.

6.6.1. Diagrama a) — el hipergrafo del TT

Hay **dos filas de nodos**:

Fila de arriba	**Fila de abajo**
Nodos grises $I_0, I_1, \ldots, I_{d-2}$	Nodos grises $X_0, X_1, \ldots, X_{d-1}$
Son las **variables ocultas**: los indices internos α_k que nunca aparecen en los datos. Son $d-1$ en total.	Son las **variables visibles**: las dimensiones del tensor. Son d en total (una mas que los nodos ocultos).

Lo que hace diferente al TT del CP es la **estructura de las aristas**. Observa que hay tres patrones distintos en el diagrama a):

Arista	**Conecta**	**Tipo**	**Tensor asociado**
e_0	X_0 y I_0	Extremo izquierdo (grado 2)	Matriz $\tau^0 \in \mathbb{R}^{m_0 \times n_0}$
e_k	X_k, I_{k-1} e I_k	**Interna (grado 3)**	Tensor orden 3: $\tau^k \in \mathbb{R}^{m_k \times n_{k-1} \times n_k}$
e_{d-1}	X_{d-1} e I_{d-2}	Extremo derecho (grado 2)	Matriz $\tau^{d-1} \in \mathbb{R}^{m_{d-1} \times n_{d-2}}$

La diferencia crucial con el CP: las aristas internas del TT tocan **tres nodos** (X_k, I_{k-1} e I_k), por eso llevan un tensor de orden 3 en lugar de una simple matriz.

Figura 3a — hipergrafo del formato TT (caso $d = 4$)

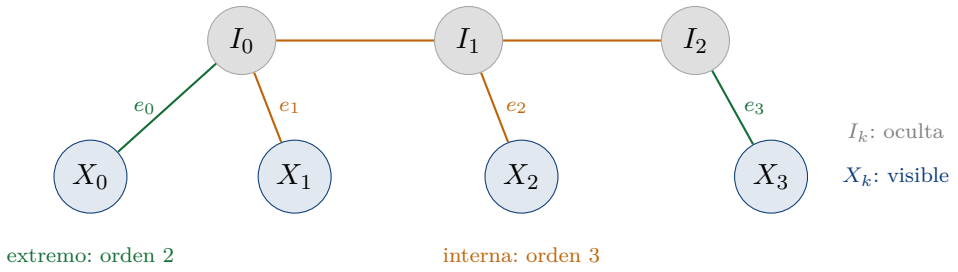

6.6.2. Diagrama b) — la red tensorial del TT

En el diagrama b) los cuadros $\tau^0, \tau^1, \ldots, \tau^{d-1}$ son los tensores de factor y las lineas son los indices. Hay que distinguir dos tipos de lineas:

- **Lineas horizontales** etiquetadas $I_0, I_1, \ldots, I_{d-2}$: son los **indices internos** que se contraen (se suman). Conectan un cuadro con el siguiente, como un cable que pasa el estado de izquierda a derecha.
- **Lineas verticales** etiquetadas $X_0, X_1, \ldots, X_{d-1}$: son los **indices libres**, las dimensiones del tensor final. Salen hacia abajo de cada cuadro.

Cuenta las lineas de cada cuadro:

Cuadro	Lineas horiz.	Lineas vert.	Orden del tensor
τ^0 (extremo izq.)	1 (hacia I_0)	1 (hacia X_0)	2 (matriz)
τ^k (interno)	2 (I_{k-1} y I_k)	1 (hacia X_k)	3
τ^{d-1} (extremo der.)	1 (desde I_{d-2})	1 (hacia X_{d-1})	2 (matriz)

Figura 3b — red tensorial del TT (caso $d = 4$)

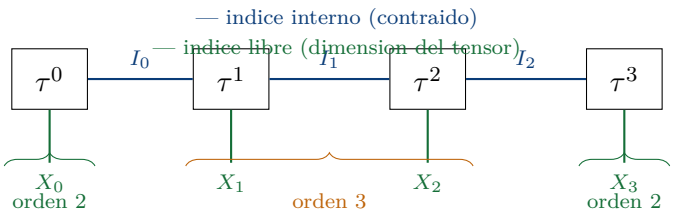

6.6.3. La historia que cuenta el diagrama b): una linea de ensamblaje

La forma mas intuitiva de leer el diagrama b) es como una **linea de produccion en una fabrica**:

1. τ^0 recibe el dato X_0 y produce un "estado interno" I_0 de dimension n_0. Es como la primera maquina que transforma la materia prima en un semielaborado.
2. τ^1 recibe ese estado I_0 mas el dato X_1, y produce el siguiente estado I_1. Cada maquina recibe el semielaborado anterior y agrega informacion nueva.
3. Asi sucesivamente hasta τ^{d-1}, que recibe el ultimo estado I_{d-2} y el dato X_{d-1} y produce el resultado final.

Matematicamente, esto es el producto de matrices que ya conocemos:

$$\mathcal{A}_{i_0,i_1,\ldots,i_{d-1}} = \tau^0[i_0,\,:] \cdot \tau^1[i_1,\,:,\,:] \cdot \tau^2[i_2,\,:,\,:] \cdots \tau^{d-1}[i_{d-1},\,:]$$

Fijados los indices libres $i_0, i_1, \ldots, i_{d-1}$, cada factor interno $\tau^k[i_k, :, :]$ se convierte en una matriz ordinaria, y el resultado es el producto de todas esas matrices.

Analogia con electricidad y magnetismo: El filtro digital IIR

Un filtro digital de respuesta infinita al impulso (IIR) actualiza su estado interno $s[k]$ a cada paso:

$$s[k] = A\,s[k-1] + B\,x[k], \qquad y[k] = C\,s[k]$$

donde $x[k]$ es la senal de entrada (el dato X_k), $s[k]$ es el estado interno (el indice I_k), y A, B, C son matrices de parametros (los factores τ^k). El tensor train es exactamente la version multidimensional de este mecanismo: cada τ^k es la funcion de transferencia de la k-esima etapa del filtro.

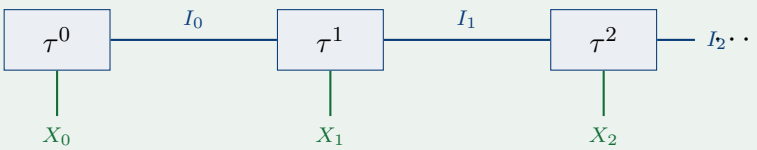

Estado interno $I_k \equiv s[k]$ del filtro IIR
Dato de entrada $X_k \equiv x[k]$
Factor $\tau^k \equiv$ matrices A, B, C del filtro

Ejercicio 4.1

Dada la matriz $\mathbf{M} = \begin{pmatrix} 6 & 3 \\ 4 & 2 \end{pmatrix}$, tiene rango 1? Si es asi, encuentra vectores $\mathbf{u}$ y $\mathbf{v}$ tales que $\mathbf{M} = \mathbf{u}\,\mathbf{v}^\top$. Escribe el resultado en notacion del paper: τ^{e_0} y τ^{e_1}.

Ejercicio 4.2

Un tensor de orden 4 con dimensiones $m_0 = m_1 = m_2 = m_3 = 10$.

a) Cuantas entradas tiene en representacion densa?

b) Con CP de rango $n = 3$: cuantos parametros tiene cada τ^{e_k} y cuantos en total?

c) Con TT de rangos $n_0 = n_1 = n_2 = 3$: cuantos parametros tiene cada τ^{e_k}

(distingue extremos de internos) y cuantos en total?

d) Cual formato es mas compacto en este caso?

6.7. Figura 4 del paper: contraccion con variables abiertas

Esta figura es el corazon del formalismo: muestra exactamente **como se contrae una red tensorial** y que significa tener variables "abiertas" versus variables "contraidas".

6.7.1. Que dice la figura

La figura establece una igualdad entre dos cosas:

Lado izquierdo		**Lado derecho**
El tensor resultante $\langle \tau^{e_0}, \tau^{e_1}, \tau^{e_2} \rangle_{[X_1,X_3]}$ con dos indices libres (X_1 y X_3).	=	La red tensorial formada por los tres cuadros τ^{e_0}, τ^{e_1}, τ^{e_2} conectados con sus indices contraidos y abiertos.

6.7.2. La notacion $\langle \cdot \rangle_{[X_1,X_3]}$

Los corchetes angulares $\langle \cdot \rangle$ significan **contraccion de red tensorial**. El subindice $[X_1, X_3]$ dice cuales variables quedan **abiertas** (libres, el resultado depende de ellas). Todo lo que **no** aparece en $[X_1, X_3]$ se **contrae** (se suma y desaparece del resultado).

Variable	**Tipo**	**Que le pasa**
X_1	Abierta (libre)	Queda en el resultado. El tensor final depende de x_1.
X_3	Abierta (libre)	Queda en el resultado. El tensor final depende de x_3.
X_0	Contraida	Se suma sobre todos sus valores. Desaparece del resultado.
X_2	Contraida	Se suma sobre todos sus valores. Desaparece del resultado.

6.7.3. La regla del punto — como leer el diagrama

El caption de la figura da la regla clave:

Regla del punto: Las variables **abiertas** (libres) se dibujan con lineas que **no tienen punto** en el extremo. Las variables **contraidas** se dibujan con lineas que **tienen un punto negro** en el extremo donde se conectan con otro tensor.

6.7.4. Recreacion del diagrama de la Figura 4

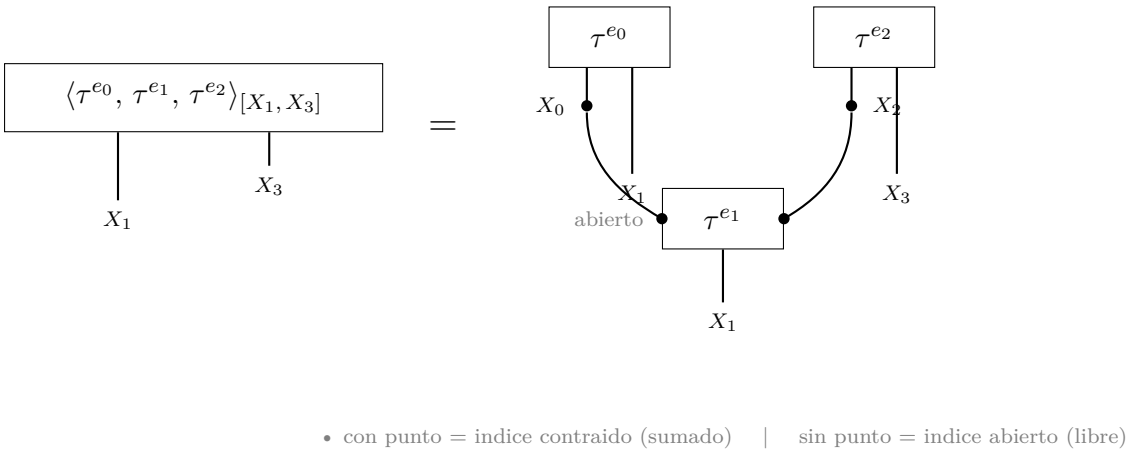

6.7.5. Como leer cada cuadro del diagrama

Tensor	Lineas con punto	Lineas sin punto	Que hace
τ^{e_0}	X_0 (contraido)	X_1 (libre)	Matricialmente: fija x_1, suma sobre x_0
τ^{e_1}	X_0 y X_2 (contraidos, recibidos por curvas)	X_1 (libre)	Recibe los dos indices sumados y el libre x_1
τ^{e_2}	X_2 (contraido)	X_3 (libre)	Matricialmente: fija x_3, suma sobre x_2

6.7.6. La formula matematica completa

Juntando todo, la contraccion de la Figura 4 es:

$$\boxed{\langle \tau^{e_0}, \tau^{e_1}, \tau^{e_2} \rangle_{[X_1,X_3]}(x_1, x_3) \;=\; \sum_{x_0} \sum_{x_2} \tau^{e_0}[x_0,\, x_1] \cdot \tau^{e_1}[x_0,\, x_1,\, x_2] \cdot \tau^{e_2}[x_2,\, x_3]}$$

El resultado es un tensor de orden 2 (una matriz en x_1 y x_3) porque sumamos sobre x_0 y x_2 y dejamos libres x_1 y x_3.

Ejemplo 4.6 — Figura 4 con numeros concretos

Usamos dimensiones pequenas: $x_0, x_1, x_2, x_3 \in \{0, 1\}$. Los tres tensores (con indices en orden $[X_0, X_1]$, $[X_0, X_1, X_2]$, $[X_2, X_3]$):

$$\tau^{e_0} = \begin{pmatrix} 1 & 2 \\ 0 & 1 \end{pmatrix}, \quad \tau^{e_2} = \begin{pmatrix} 1 & 0 \\ 1 & 2 \end{pmatrix}$$

$$\tau^{e_1}[x_0{=}0,\, :,\, :] = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}, \quad \tau^{e_1}[x_0{=}1,\, :,\, :] = \begin{pmatrix} 2 & 1 \\ 1 & 0 \end{pmatrix}$$

Calculamos la entrada ($x_1{=}0$, $x_3{=}1$) del tensor resultado:

$$R(0,\,1) = \sum_{x_0\in\{0,1\}} \sum_{x_2\in\{0,1\}} \tau^{e_0}[x_0,\,0]\cdot\tau^{e_1}[x_0,\,0,\,x_2]\cdot\tau^{e_2}[x_2,\,1]$$

Expandimos los cuatro terminos:

$$\begin{aligned}
(x_0{=}0,\,x_2{=}0):&\quad \tau^{e_0}[0,0]\cdot\tau^{e_1}[0,0,0]\cdot\tau^{e_2}[0,1] = (1)(1)(0) = 0\\
(x_0{=}0,\,x_2{=}1):&\quad \tau^{e_0}[0,0]\cdot\tau^{e_1}[0,0,1]\cdot\tau^{e_2}[1,1] = (1)(0)(2) = 0\\
(x_0{=}1,\,x_2{=}0):&\quad \tau^{e_0}[1,0]\cdot\tau^{e_1}[1,0,0]\cdot\tau^{e_2}[0,1] = (0)(2)(0) = 0\\
(x_0{=}1,\,x_2{=}1):&\quad \tau^{e_0}[1,0]\cdot\tau^{e_1}[1,0,1]\cdot\tau^{e_2}[1,1] = (0)(1)(2) = 0
\end{aligned}$$

$$R(0,\,1) = 0+0+0+0 = 0$$

Ahora calculamos $(x_1{=}1,\,x_3{=}0)$:

$$\begin{aligned}
(x_0{=}0,\,x_2{=}0):&\quad \tau^{e_0}[0,1]\cdot\tau^{e_1}[0,1,0]\cdot\tau^{e_2}[0,0] = (2)(0)(1) = 0\\
(x_0{=}0,\,x_2{=}1):&\quad \tau^{e_0}[0,1]\cdot\tau^{e_1}[0,1,1]\cdot\tau^{e_2}[1,0] = (2)(1)(1) = 2\\
(x_0{=}1,\,x_2{=}0):&\quad \tau^{e_0}[1,1]\cdot\tau^{e_1}[1,1,0]\cdot\tau^{e_2}[0,0] = (1)(1)(1) = 1\\
(x_0{=}1,\,x_2{=}1):&\quad \tau^{e_0}[1,1]\cdot\tau^{e_1}[1,1,1]\cdot\tau^{e_2}[1,0] = (1)(0)(1) = 0
\end{aligned}$$

$$R(1,\,0) = 0+2+1+0 = 3$$

El tensor resultado $R(x_1, x_3)$ es una matriz 2×2. Hemos calculado dos de sus cuatro entradas.

Analogia con electricidad y magnetismo: El cuadripolo electrico

En electronica, un **cuadripolo** (o two-port network) es una caja negra con dos pares de terminales: entrada (V_1, I_1) y salida (V_2, I_2). Dentro de la caja puede haber resistencias, capacitores e inductores en cualquier configuracion — los nodos internos son las variables contraidas. Lo que importa desde fuera son solo los parametros de los terminales (los indices abiertos).

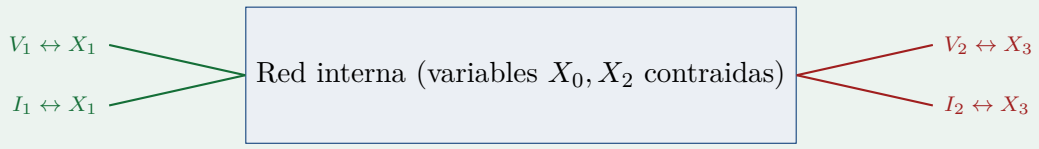

La contraccion $\langle \tau^{e_0}, \tau^{e_1}, \tau^{e_2}\rangle_{[X_1,X_3]}$ es la **matriz de parametros S** que describe el cuadripolo completo desde sus terminales externos.

Exactamente como la matriz de parametros S de un cuadripolo resume todo el comportamiento interno en una sola matriz 2×2, la contraccion tensorial resume toda la red interna en un tensor que solo depende de los indices abiertos.

Idea clave

Esta figura contiene la idea mas profunda del paper: puedes tomar varios tensores, conectarlos compartiendo indices, sumar sobre los indices internos (contraidos) y obtener un tensor nuevo que solo depende de las variables que te interesan (abiertas). Eso es exactamente lo que hace la inferencia probabilistica (calcular marginales), la evaluacion de formulas logicas y la propagacion en redes neuronales. **Todo es contraccion de redes tensoriales.**

Ejercicio 4.3

Usando los tensores del Ejemplo 4.6, calcula las dos entradas que faltan del tensor resultado $R(x_1, x_3)$: es decir, $R(0,0)$ y $R(1,1)$. Luego escribe la matriz completa $R \in \mathbb{R}^{2\times 2}$.

Ejercicio 4.4

Dado el mismo diagrama de la Figura 4 pero con las variables abiertas cambiadas a $[X_0, X_2]$ en lugar de $[X_1, X_3]$:

a) Cuales variables se contraen ahora?

b) Cual es la formula de suma correspondiente?

c) Que dimensiones tiene el tensor resultado?

6.8. Figura 5 del paper: variables independientes

Esta figura es el **caso mas simple posible** de distribucion de probabilidad en el formalismo tensorial: variables completamente independientes. Es el punto de partida antes de anadir dependencias.

6.8.1. Diagrama a) — el hipergrafo elemental

Cada variable X_k es un nodo **aislado**, conectado solo a su propia arista e_k. **No hay ninguna arista que conecte dos variables entre si.**

Eso es exactamente la definicion matematica de independencia:

$$\mathbb{P}(X_0, X_1, \ldots, X_{d-1}) = \mathbb{P}^0(X_0) \cdot \mathbb{P}^1(X_1) \cdots \mathbb{P}^{d-1}(X_{d-1})$$

Cada variable vive en su propio mundo, sin influir en las demas. El paper llama "hipergrafo elemental" a esta estructura porque sus aristas contienen un solo nodo cada una.

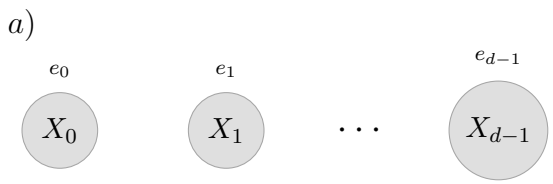

Sin conexiones entre variables ⇒ independencia

Comparando con las figuras anteriores, la diferencia es radical:

Figura	**Conexiones**	**Significado**
Fig. 5 (esta)	Ninguna	Variables independientes
Fig. 2 (CP)	Estrella: todas a I	Todas dependen de un factor comun
Fig. 3 (TT)	Cadena: $I_0, I_1, \ldots$	Dependencia con vecinos
Fig. 4	Red general	Dependencias arbitrarias

6.8.2. Diagrama b) — la red tensorial de independencia

El cuadro grande $\mathbb{P}$ con todos los indices $X_0, \ldots, X_{d-1}$ es igual al producto de cuadros pequenos $\mathbb{P}^0, \mathbb{P}^1, \ldots, \mathbb{P}^{d-1}$, donde cada uno tiene **un solo indice vertical** y **ninguna linea horizontal**.

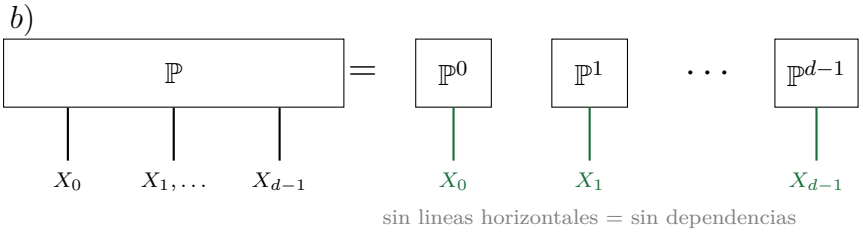

Las tres caracteristicas clave del diagrama b):

1. **No hay lineas horizontales entre cuadros.** En el TT (Fig. 3) habia lineas I_k que conectaban cuadros vecinos. Aqui no hay ninguna. Eso es independencia: cada cuadro ignora a los demas.

2. **Cada cuadro $\mathbb{P}^k$ tiene solo una linea vertical** (el indice X_k). Es un simple **vector de probabilidades**:

$$\mathbb{P}^k \in \mathbb{R}^{m_k}, \quad \mathbb{P}^k(x_k) = \mathbb{P}(X_k = x_k)$$

   Es decir, es la distribucion marginal de X_k.

3. **Todas las variables son abiertas.** No hay nada que contraer. El resultado es simplemente el producto de los factores individuales.

6.8.3. La formula matematica

$$\boxed{\mathbb{P}[X_{[d]}](x_0, x_1, \ldots, x_{d-1}) \;=\; \prod_{k=0}^{d-1} \mathbb{P}^k(x_k)}$$

En notacion de contraccion tensorial del paper:

$$\mathbb{P} = \langle \mathbb{P}^0, \mathbb{P}^1, \ldots, \mathbb{P}^{d-1} \rangle_{[X_0, X_1, \ldots, X_{d-1}]}$$

Todas las variables son abiertas. No se contrae nada.

Ejemplo 4.7 — Figura 5 con numeros ($d = 3$ variables binarias)

Tres monedas independientes con probabilidades:

$$\mathbb{P}^0 = \begin{pmatrix} 0.7 \\ 0.3 \end{pmatrix}, \quad \mathbb{P}^1 = \begin{pmatrix} 0.5 \\ 0.5 \end{pmatrix}, \quad \mathbb{P}^2 = \begin{pmatrix} 0.4 \\ 0.6 \end{pmatrix}$$

donde el indice $0 =$ cara y $1 =$ sello.
La probabilidad conjunta de ($X_0 =$ cara, $X_1 =$ sello, $X_2 =$ cara):

$$\mathbb{P}(0,\ 1,\ 0) = \mathbb{P}^0(0) \cdot \mathbb{P}^1(1) \cdot \mathbb{P}^2(0) = 0.7 \times 0.5 \times 0.4 = 0.14$$

No hay suma que hacer: el producto directo lo da todo. El tensor conjunto $\mathbb{P} \in \mathbb{R}^{2\times2\times2}$ tiene 8 entradas, pero basta guardar $2+2+2 = 6$ numeros (los tres vectores marginales) porque las variables son independientes. Ahorro: de 8 a 6 parametros. Para $d = 100$ variables binarias: de $2^{100} \approx 10^{30}$ a solo 200 numeros.

Analogia con electricidad y magnetismo: Circuitos en paralelo sin acoplamiento mutuo

Variables independientes en probabilidad es equivalente a **ramas paralelas sin acoplamiento mutuo** en un circuito electrico. Cada rama tiene su propia impedancia Z_k y la corriente en cada rama no afecta a las demas. No hay transformadores de acoplamiento mutuo.
Cuando hay dependencias entre variables (Figs. 2, 3, 4) es como anadir transformadores de acoplamiento: la corriente en una rama influye en las otras. Cuantas mas dependencias, mas acoplamiento, mas parametros necesitamos para describir el sistema.

Ejercicio 4.5

Tres dados de seis caras ($x_k \in \{1, 2, 3, 4, 5, 6\}$) independientes, cada uno con distribucion uniforme: $\mathbb{P}^k(x_k) = 1/6$.

a) Cuantas entradas tiene el tensor conjunto $\mathbb{P}$?

b) Cuantos parametros necesitamos realmente?

c) Calcula $\mathbb{P}(3, 1, 5)$.

d) Si los dados **no** fueran independientes (por ejemplo, el segundo depende del primero), cuantos parametros adicionales necesitariamos para describir la dependencia entre X_0 y X_1?

7. Modulo 5: codificacion en base — datos como tensores

7.1. Como convertir datos en vectores

Ejemplo 5.1 — Codificacion one-hot para datos discretos

Si x puede valer 0 o 1, lo codificamos como:

$$\mathbf{e}_0 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \qquad \mathbf{e}_1 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$$

Para tres colores (rojo, verde, azul):

$$\text{rojo} \to \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}, \quad \text{verde} \to \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix}, \quad \text{azul} \to \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}$$

El vector tiene exactamente un "1" y el resto "0".

Ejemplo 5.2 — Codificacion con polinomios para datos continuos

Sea $x \in [-1, 1]$. Elegimos como base los tres primeros polinomios de Legendre:

$$P_0(x) = 1, \qquad P_1(x) = x, \qquad P_2(x) = \tfrac{1}{2}(3x^2 - 1)$$

La codificacion de x es:

$$\boldsymbol{\phi}(x) = \begin{pmatrix} P_0(x) \\ P_1(x) \\ P_2(x) \end{pmatrix} = \begin{pmatrix} 1 \\ x \\ \frac{1}{2}(3x^2 - 1) \end{pmatrix}$$

Para $x = 0.5$:

$$\boldsymbol{\phi}(0.5) = \begin{pmatrix} 1 \\ 0.5 \\ \frac{1}{2}(0.75 - 1) \end{pmatrix} = \begin{pmatrix} 1 \\ 0.5 \\ -0.125 \end{pmatrix}$$

Analogia con electricidad y magnetismo: Series de Fourier en electromagnetismo

En una cavidad resonante, el campo electrico se expande en modos normales:

$$E(x, t) = \sum_n a_n \sin\left(\frac{n\pi x}{L}\right) \cos(\omega_n t)$$

Los coeficientes a_n son la "codificacion" del campo en la base de modos normales. La codificacion en base del paper hace lo mismo: expresa un dato x en terminos de funciones base $\phi_k(x)$, y los coeficientes forman el vector de entrada.

Ejemplo 5.3 — Producto tensorial de dos codificaciones

Para el par $(x_1 = 1,\ x_2 = 0)$ con codificacion one-hot:

$$\mathbf{e}_1 \otimes \mathbf{e}_0 = \begin{pmatrix} 0 \\ 1 \end{pmatrix} \otimes \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 0 \cdot 1 \\ 0 \cdot 0 \\ 1 \cdot 1 \\ 1 \cdot 0 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 1 \\ 0 \end{pmatrix}$$

Este vector tiene exactamente un "1" en la posicion que corresponde al par $(1, 0)$.

Ejercicio 5.1

Usa codificacion one-hot para $x_1, x_2 \in \{0, 1\}$. Calcula $\mathbf{e}_0 \otimes \mathbf{e}_0$, $\mathbf{e}_0 \otimes \mathbf{e}_1$ y $\mathbf{e}_1 \otimes \mathbf{e}_1$. En que posicion queda el "1" en cada caso?

8. Modulo 6: logica proposicional como tensores

8.1. Variables verdadero/falso como vectores

Con codificacion one-hot:

$$\text{falso } (0) = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \qquad \text{verdadero } (1) = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$$

8.2. Las conectivas logicas como tensores

Ejemplo 6.1 — El tensor NOT

La negacion intercambia verdadero y falso. Como matriz:

$$\mathbf{T}_{\text{NOT}} = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$$

Verificacion: NOT(falso) = verdadero

$$\mathbf{T}_{\text{NOT}} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 0 \cdot 1 + 1 \cdot 0 \\ 1 \cdot 1 + 0 \cdot 0 \end{pmatrix} = \begin{pmatrix} 0 \\ 1 \end{pmatrix} = \text{verdadero} \quad \checkmark$$

Verificacion: NOT(verdadero) = falso

$$\mathbf{T}_{\text{NOT}} \begin{pmatrix} 0 \\ 1 \end{pmatrix} = \begin{pmatrix} 0 \cdot 0 + 1 \cdot 1 \\ 1 \cdot 0 + 0 \cdot 1 \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \text{falso} \quad \checkmark$$

Ejemplo 6.2 — El tensor AND

El AND produce verdadero solo si ambas entradas son verdaderas. Como tensor de orden 3 con indices $k,\ i_1,\ i_2 \in \{0, 1\}$:

$$(\mathcal{T}_{\text{AND}})_{k, i_1, i_2} = 1 \ \text{ si } \ k = i_1 \cdot i_2, \quad 0 \ \text{ en caso contrario}$$

Las entradas no nulas:

i_1	i_2	$k = i_1 \cdot i_2$	entrada
0	0	0	$(\mathcal{T}_{\text{AND}})_{0,0,0} = 1$
0	1	0	$(\mathcal{T}_{\text{AND}})_{0,0,1} = 1$
1	0	0	$(\mathcal{T}_{\text{AND}})_{0,1,0} = 1$
1	1	1	$(\mathcal{T}_{\text{AND}})_{1,1,1} = 1$

Verificacion: verdadero AND verdadero = verdadero

$$\sum_{i_1,i_2} (\mathcal{T}_{\text{AND}})_{k,i_1,i_2} (e_1)_{i_1} (e_1)_{i_2} = (\mathcal{T}_{\text{AND}})_{k,1,1} = \begin{pmatrix} 0 \\ 1 \end{pmatrix} = \text{verdadero} \quad \checkmark$$

Verificacion: verdadero AND falso = falso

$$\sum_{i_1,i_2} (\mathcal{T}_{\text{AND}})_{k,i_1,i_2} (e_1)_{i_1} (e_0)_{i_2} = (\mathcal{T}_{\text{AND}})_{k,1,0} = \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \text{falso} \quad \checkmark$$

Analogia con electricidad y magnetismo: Compuertas logicas y circuitos digitales

En electronica digital, una compuerta AND es un componente que recibe dos senales y produce una salida. El tensor $\mathcal{T}_{\text{AND}}$ es exactamente la **tabla de verdad** de esa compuerta, pero escrita en lenguaje tensorial. La ventaja es que ahora podemos **componer** compuertas haciendo contracciones, igual que conectamos compuertas en un circuito.

Ejemplo 6.3 — Evaluacion de x_1 AND (NOT x_2)

Queremos evaluar $\varphi = x_1 \wedge (\neg x_2)$ para $x_1 = 1$, $x_2 = 1$.
Paso 1: codificamos las variables.

$$\mathbf{e}_{x_1=1} = \begin{pmatrix} 0 \\ 1 \end{pmatrix}, \quad \mathbf{e}_{x_2=1} = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$$

Paso 2: aplicamos NOT a x_2.

$$\mathbf{T}_{\text{NOT}}\, \mathbf{e}_1 = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} 0 \\ 1 \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \mathbf{e}_0$$

Ahora tenemos $\neg x_2 = 0$.
Paso 3: aplicamos AND entre $x_1 = 1$ y $\neg x_2 = 0$.

$$(\mathcal{T}_{\text{AND}})_{k,1,0} = \begin{cases} 1 & k = 0 \\ 0 & k = 1 \end{cases} = \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \text{falso}$$

Resultado: $1 \wedge (\neg 1) = 1 \wedge 0 = 0$. Correcto.

Ejercicio 6.1

Construye el tensor $\mathcal{T}_{\text{OR}}$. El OR produce verdadero si al menos una entrada es verdadera. Escribe todas las entradas no nulas y verifica que falso OR verdadero = verdadero calculando la contraccion.

9. Modulo 7: probabilidad como tensores

Ejemplo 7.1 — Distribucion de dos variables binarias

Sean $x_1, x_2 \in \{0, 1\}$ con distribucion:

x_1	x_2	$p(x_1, x_2)$
0	0	0.10
0	1	0.40
1	0	0.30
1	1	0.20

Esta tabla es exactamente el tensor $\mathcal{P} \in \mathbb{R}^{2\times 2}$:

$$\mathcal{P} = \begin{pmatrix} 0.10 & 0.40 \\ 0.30 & 0.20 \end{pmatrix}$$

Para obtener $p(x_1 = 1,\, x_2 = 0)$ hacemos la contraccion:

$$p(1, 0) = \mathbf{e}_1^\top \mathcal{P}\, \mathbf{e}_0 = (0,\ 1) \begin{pmatrix} 0.10 \\ 0.30 \end{pmatrix} = 0.30 \quad \checkmark$$

Ejemplo 7.2 — Marginalizacion como contraccion

La probabilidad marginal de x_1 se obtiene sumando sobre x_2:

$$p(x_1) = \sum_{x_2 \in \{0,1\}} p(x_1, x_2)$$

En forma matricial, contraemos $\mathcal{P}$ con el vector de unos $\mathbf{1} = (1, 1)^\top$:

$$\mathbf{p}_{x_1} = \mathcal{P}\, \mathbf{1} = \begin{pmatrix} 0.10 & 0.40 \\ 0.30 & 0.20 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 0.50 \\ 0.50 \end{pmatrix}$$

Ambos valores de x_1 tienen probabilidad 0.5.

Analogia con electricidad y magnetismo: Ley de Kirchhoff y conservacion de corriente

En un nodo electrico, la corriente que entra es igual a la que sale: $\sum_j I_j = 0$. La marginalizacion en probabilidad es analoga: sumar sobre una variable es como integrar la corriente que pasa por un nodo. En ambos casos, contraemos con el vector de unos para acumular contribuciones a lo largo de una dimension.

Ejemplo 7.3 — Modelo de cadena simple con tres variables

Tres variables binarias con potenciales:

$$\boldsymbol{\psi}_1 = \begin{pmatrix} 0.6 \\ 0.4 \end{pmatrix}, \quad \boldsymbol{\Psi}_{12} = \begin{pmatrix} 0.8 & 0.2 \\ 0.3 & 0.7 \end{pmatrix}, \quad \boldsymbol{\Psi}_{23} = \begin{pmatrix} 0.9 & 0.1 \\ 0.4 & 0.6 \end{pmatrix}$$

La distribucion no normalizada es:

$$\tilde{p}(x_1, x_2, x_3) = (\psi_1)_{x_1} \cdot (\Psi_{12})_{x_1,x_2} \cdot (\Psi_{23})_{x_2,x_3}$$

Para $(x_1 = 0,\ x_2 = 0,\ x_3 = 1)$:

$$\tilde{p}(0, 0, 1) = 0.6 \times 0.8 \times 0.1 = 0.048$$

Ejercicio 7.1

Con los potenciales del ejemplo 7.3, calcula $\tilde{p}$ para las 8 configuraciones posibles $(x_1, x_2, x_3) \in \{0, 1\}^3$. Luego calcula la constante de normalizacion $Z = \sum \tilde{p}$ y verifica que las probabilidades normalizadas suman 1.

10. Modulo 8: paso de mensajes — inferencia eficiente

Idea clave

El paso de mensajes calcula probabilidades marginales de forma eficiente, evitando sumar sobre todas las configuraciones posibles. Un **mensaje** $\mu_{j\to k}(x_k)$ resume toda la informacion que el nodo j transmite al nodo k.

Ejemplo 8.1 — Algoritmo hacia adelante en una cadena

Usamos el modelo del ejemplo 7.3. Queremos calcular $p(x_3)$ sin sumar explicitamente todas las configuraciones.

Paso 1: mensaje de x_1 a x_2

$$\mu_{1\to 2}(x_2) = \sum_{x_1} (\psi_1)_{x_1} \cdot (\Psi_{12})_{x_1,x_2}$$

$$\mu_{1\to 2}(0) = 0.6 \times 0.8 + 0.4 \times 0.3 = 0.48 + 0.12 = 0.60$$

$$\mu_{1\to 2}(1) = 0.6 \times 0.2 + 0.4 \times 0.7 = 0.12 + 0.28 = 0.40$$

En forma vectorial: $\boldsymbol{\mu}_{1\to 2} = (0.60,\ 0.40)^\top$.

Paso 2: mensaje de x_2 a x_3

$$\mu_{2\to 3}(x_3) = \sum_{x_2} \mu_{1\to 2}(x_2) \cdot (\Psi_{23})_{x_2,x_3}$$

$$\mu_{2\to 3}(0) = 0.60 \times 0.9 + 0.40 \times 0.4 = 0.54 + 0.16 = 0.70$$

$$\mu_{2\to 3}(1) = 0.60 \times 0.1 + 0.40 \times 0.6 = 0.06 + 0.24 = 0.30$$

Resultado: $p(x_3 = 0) = 0.70$, $p(x_3 = 1) = 0.30$.
Cada mensaje es simplemente un **producto matriz-vector**, es decir, una contraccion tensorial.

Analogia con electricidad y magnetismo: Senal que viaja por amplificadores en serie

Una senal electrica que pasa por n amplificadores en cascada: cada amplificador recibe la senal anterior, la transforma con su funcion de transferencia y la pasa al siguiente. El algoritmo de paso de mensajes hace lo mismo con probabilidades: la informacion "fluye" de nodo en nodo, acumulandose en el mensaje.

Ejercicio 8.1

Usando el ejemplo 8.1, calcula ahora el mensaje "hacia atras": desde x_3 hasta x_1. Parte del vector $\boldsymbol{\mu}_{3\to 2} = (0.70,\ 0.30)^\top$ y propaga multiplicando por las matrices de potencial en sentido inverso.

11. Modulo 9: redes neuronales como redes tensoriales

11.1. Una capa neuronal es una contraccion tensorial

Una red neuronal estandar tiene capas de la forma:

$$\mathbf{h} = \sigma(\mathbf{W}\mathbf{x} + \mathbf{b})$$

donde $\mathbf{W}$ es la matriz de pesos, $\mathbf{b}$ el vector de sesgos, y σ una funcion de activacion (ReLU, sigmoide, etc.). La operacion $\mathbf{W}\mathbf{x}$ es exactamente una contraccion tensorial: el producto matriz-vector.

Ejemplo 9.1 — Una capa neuronal paso a paso

Sea $\mathbf{W} = \begin{pmatrix} 2 & 1 \\ 0 & 3 \end{pmatrix}$, $\mathbf{b} = \begin{pmatrix} 1 \\ -1 \end{pmatrix}$, activacion ReLU: $\sigma(t) = \text{máx}(0, t)$.

Entrada $\mathbf{x} = \begin{pmatrix} 1 \\ 2 \end{pmatrix}$:

Paso 1 (contraccion):

$$\mathbf{W}\mathbf{x} = \begin{pmatrix} 2 \cdot 1 + 1 \cdot 2 \\ 0 \cdot 1 + 3 \cdot 2 \end{pmatrix} = \begin{pmatrix} 4 \\ 6 \end{pmatrix}$$

Paso 2 (sesgo):

$$\mathbf{W}\mathbf{x} + \mathbf{b} = \begin{pmatrix} 4 + 1 \\ 6 - 1 \end{pmatrix} = \begin{pmatrix} 5 \\ 5 \end{pmatrix}$$

Paso 3 (activacion):

$$\mathbf{h} = \text{ReLU}\begin{pmatrix} 5 \\ 5 \end{pmatrix} = \begin{pmatrix} 5 \\ 5 \end{pmatrix}$$

Ejemplo 9.2 — Red de 3 capas como tensor train

$$\mathbf{W}^{(1)} = \begin{pmatrix} 1 & 0 \\ 1 & 1 \end{pmatrix}, \quad \mathbf{W}^{(2)} = \begin{pmatrix} 2 & 1 \\ 0 & 1 \end{pmatrix}, \quad \mathbf{W}^{(3)} = \begin{pmatrix} 1 & -1 \\ 0 & 2 \end{pmatrix}$$

Entrada $\mathbf{x} = (1,\ 0)^\top$ (sin activaciones, red lineal):

Capa 1: $\mathbf{h}^{(1)} = \mathbf{W}^{(1)}\mathbf{x} = \begin{pmatrix} 1 \cdot 1 + 0 \cdot 0 \\ 1 \cdot 1 + 1 \cdot 0 \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$

Capa 2: $\mathbf{h}^{(2)} = \mathbf{W}^{(2)}\mathbf{h}^{(1)} = \begin{pmatrix} 2 \cdot 1 + 1 \cdot 1 \\ 0 \cdot 1 + 1 \cdot 1 \end{pmatrix} = \begin{pmatrix} 3 \\ 1 \end{pmatrix}$

Capa 3: $\mathbf{y} = \mathbf{W}^{(3)}\mathbf{h}^{(2)} = \begin{pmatrix} 1 \cdot 3 + (-1) \cdot 1 \\ 0 \cdot 3 + 2 \cdot 1 \end{pmatrix} = \begin{pmatrix} 2 \\ 2 \end{pmatrix}$

Esta cadena de multiplicaciones de matrices es exactamente un **tensor train**.

Analogia con electricidad y magnetismo: Parametros S en cascada (circuitos de RF)

En un circuito de radiofrecuencia, los componentes en cascada (amplificadores, filtros, mezcladores) se describen mediante matrices de parametros S. La respuesta total del sistema es el producto:

$$S_{\text{total}} = S_n \cdots S_2 \cdot S_1$$

Una red neuronal profunda lineal es matematicamente identica a esta cascada: cada capa es una "etapa de RF" descrita por su matriz de pesos.

Ejercicio 9.1

Calcula $\mathbf{W}_{\text{total}} = \mathbf{W}^{(3)}\mathbf{W}^{(2)}\mathbf{W}^{(1)}$ del ejemplo 9.2 multiplicando las tres matrices paso a paso. Verifica que $\mathbf{W}_{\text{total}}\,(1,\ 0)^\top = (2,\ 2)^\top$.

12. Modulo 10: el modelo final — hybrid logic network

Idea clave

El Hybrid Logic Network (HLN) es una distribucion de probabilidad donde las "energias" son formulas logicas con pesos aprendibles. Las configuraciones que satisfacen mas reglas logicas tienen mayor probabilidad. Los pesos se aprenden de los datos.

12.1. La distribucion del HLN

Dado un conjunto de formulas logicas $\varphi_1(\mathbf{x}), \ldots, \varphi_m(\mathbf{x})$:

$$p_\theta(\mathbf{x}) = \frac{1}{Z(\theta)} \exp\left(\sum_{j=1}^{m} w_j \cdot \varphi_j(\mathbf{x}) \right)$$

donde $w_j \in \mathbb{R}$ es el peso (importancia) de la formula φ_j, y $Z(\theta) = \sum_{\mathbf{x}} \exp(\cdots)$ normaliza la distribucion.

Ejemplo 10.1 — Un HLN con dos variables

Dos variables $x_1, x_2 \in \{0, 1\}$, formula $\varphi = x_1 \wedge x_2$, peso $w_1 = 2$.

$$p(x_1, x_2) = \frac{1}{Z} \exp\Big(2 \cdot \mathbf{1}[x_1 = 1 \text{ y } x_2 = 1]\Big)$$

Tabla de las 4 configuraciones:

x_1	x_2	φ	$\exp(2\varphi)$	p
0	0	0	$e^0 = 1.00$	$1.00/Z$
0	1	0	$e^0 = 1.00$	$1.00/Z$
1	0	0	$e^0 = 1.00$	$1.00/Z$
1	1	1	$e^2 \approx 7.39$	$7.39/Z$

$Z = 1.00 + 1.00 + 1.00 + 7.39 = 10.39$

$$p(1, 1) = \frac{7.39}{10.39} \approx 0.71$$

La configuracion $(1, 1)$, que satisface φ, tiene probabilidad 71 %. Las otras tres se reparten el 29 % restante.

Analogia con electricidad y magnetismo: La distribucion de Boltzmann

La distribucion del HLN es exactamente la distribucion de Boltzmann de la fisica estadistica:

$$p(\mathbf{x}) = \frac{1}{Z} e^{-\beta E(\mathbf{x})}$$

donde $E(\mathbf{x})$ es la energia del estado $\mathbf{x}$. En el HLN, la "energia negativa" es $\sum_j w_j \varphi_j(\mathbf{x})$: los estados que satisfacen mas formulas logicas tienen menor energia (mayor probabilidad). El peso w_j juega el papel de $-\beta E_j$. El HLN es, literalmente, una maquina de Boltzmann donde las neuronas son formulas logicas.

Ejercicio 10.1

Usando el modelo del ejemplo 10.1, responde:

a) Que ocurre con la distribucion cuando $w_1 \to +\infty$? Que configuracion tiene probabilidad $\to 1$?

b) Que ocurre cuando $w_1 = 0$? Cual es la distribucion resultante?

c) Si observas los datos $\{(1, 1), (1, 1), (0, 1), (1, 1)\}$, hacia que valor deberia ajustarse w_1? Razona cualitativamente.

Ejercicio 10.2 — Proyecto integrador

Modelo de apagon electrico. Variables: x_1 = hay tormenta (0/1), x_2 = hay mantenimiento (0/1), x_3 = apagon (0/1).
Formulas del experto:

- $\varphi_1 = x_1 \wedge x_3$ (tormenta y apagon coocurren)
- $\varphi_2 = x_2 \wedge x_3$ (mantenimiento y apagon coocurren)
- $\varphi_3 = \neg x_1 \wedge \neg x_2 \wedge \neg x_3$ (sin perturbaciones no hay apagon)

Con pesos $w_1 = 3$, $w_2 = 2$, $w_3 = 1$:

a) Calcula las probabilidades no normalizadas de las 8 configuraciones posibles.

b) Cual es la configuracion mas probable? Tiene sentido fisico?

c) Calcula Z y verifica que las probabilidades normalizadas sumen 1.

Resumen general

Lo que aprendimos en este manual

1. Un **tensor** es un arreglo multidimensional de numeros.
2. La **contraccion** es la operacion fundamental: suma sobre indices compartidos, como el producto punto o la multiplicacion de matrices.
3. Una **red tensorial** conecta tensores mediante contracciones, como las resistencias en un circuito.
4. La **codificacion en base** convierte datos en vectores, como la descomposicion en modos normales.
5. La **logica proposicional** (AND, OR, NOT) se escribe como tensores, y evaluar una formula es hacer contracciones.
6. Las **distribuciones de probabilidad** son tensores; calcular marginales es una contraccion parcial.
7. Las **redes neuronales** son cadenas de contracciones (tensor trains), igual que las cascadas de parametros S en circuitos de RF.
8. El **paso de mensajes** es el mismo algoritmo para logica y probabilidad: vectores que se propagan de nodo a nodo.
9. El **Hybrid Logic Network** combina todo: es una distribucion de Boltzmann donde las "energias" son formulas logicas con pesos aprendibles.

Manual de estudio basado en Goessmann et al., arXiv:2601.15442, enero 2026.
"La naturaleza habla en tensores. Aprender a escucharla es el primer paso de la ciencia."